

Análise Automatizada de Texto

Parte I. Estado da arte, desenho de pesquisa e primeiros códigos em R
SICSS-Brazil 2026 • FGV, Rio de Janeiro

Anderson Henrique

andersonheri@gmail.com

CEM/USP • INCT QualiGov • Pesquisador Convidado IPEA

Doutor em Ciência Política pela UFPE

Summer Institute in Computational Social Science, Brazil

29 de julho de 2026

Quem sou eu

Anderson Henrique

- Pós-doutorando no **Centro de Estudos da Metrópole (CEM-USP)**, bolsista FAPESP.
- Pesquisador do **INCT QualiGov** e pesquisador visitante no **Ipea**.
- Doutor, mestre e bacharel em Ciência Política pela **UFPE**.
- Pesquisa: capacidades estatais municipais, federalismo, políticas públicas e métodos computacionais.

Materiais: github.com/andersonheri • acR: <https://ahenriquecp.com/acR/>

Por que este workshop?

- Autor do pacote acR, que integra análise de conteúdo quantitativa clássica e qualitativa assistida por LLM.
- Interesse na pergunta que organiza o dia: sob que condições a inferência sobrevive à escala?


Como o dia está organizado

Bloco	Horário	Foco
Manhã	10h15 às 12h00	Estado da arte, decisões de desenho e primeiros códigos em R
Almoço	12h00 às 13h30	Instale os pacotes; a lista está no README
Tarde	13h30 às 15h00	Pipeline completo, validação e atividade em grupos

Regras de convivência computacional

- A turma é heterogênea em R. Todo código está no repositório, comentado linha a linha. **Ninguém precisa digitar para acompanhar.**
- Todos os resultados da tarde estão **pré-computados**. Nenhuma chamada a API será feita ao vivo.
- Se travar, siga o slide. O objetivo é o raciocínio, não a digitação.

Onde a manhã começa e onde ela termina



Hoje de manhã: etapa 1 na prática (Demos 1 e 2), e o vocabulário conceitual de todas as outras, principalmente a etapa 5 (métricas de confiabilidade, o paradoxo do κ).

Hoje à tarde: as etapas 2 a 6 na prática, aplicadas ao projeto de cada um.

Por que mostrar isso agora: para você situar cada slide de hoje dentro do pipeline inteiro, e não confundir “ainda não chegamos lá” com “isso não existe”.

Ao final da manhã, você deverá ser capaz de...

- 1 **Situar** a análise automatizada de texto no debate *text-as-data* e reconhecer o que ela herda da análise de conteúdo clássica.
- 2 **Classificar** sua pergunta em uma das quatro tarefas canônicas (descrever, classificar, medir e descobrir) e escolher o método correspondente.
- 3 **Reconhecer** que pré-processamento é decisão teórica, e não etapa técnica.
- 4 **Executar** em R um fluxo mínimo: corpus, limpeza, contagem e comparação entre grupos.
- 5 **Formular** a pergunta de validação apropriada a cada método.

Nota: a manhã é conceitual, com demonstrações curtas. A tarde é prática e termina com apresentação dos grupos.

Um problema concreto para abrir

Situação

Você tem **200 mil pronunciamentos** de plenário da Câmara dos Deputados (1988 a 2024) e quer saber se o discurso sobre segurança pública se tornou mais punitivista ao longo do tempo.

Leitura humana

- Profundidade interpretativa
- Capta ironia, contexto e o latente
- Inviável na escala do corpus
- Deriva entre leitores e ao longo do tempo

Automação

- Escala arbitrária
- Consistência técnica de aplicação
- Cega ao contexto não explicitado
- Aprende os vieses do corpus de treino

Um problema concreto para abrir

Situação

Você tem **200 mil pronunciamentos** de plenário da Câmara dos Deputados (1988 a 2024) e quer saber se o discurso sobre segurança pública se tornou mais punitivista ao longo do tempo.

Leitura humana

- Profundidade interpretativa
- Capta ironia, contexto e o latente
- Inviável na escala do corpus
- Deriva entre leitores e ao longo do tempo

Automação

- Escala arbitrária
- Consistência técnica de aplicação
- Cega ao contexto não explicitado
- Aprende os vieses do corpus de treino

A pergunta correta não é qual dos dois é melhor.

Um problema concreto para abrir

Situação

Você tem **200 mil pronunciamentos** de plenário da Câmara dos Deputados (1988 a 2024) e quer saber se o discurso sobre segurança pública se tornou mais punitivista ao longo do tempo.

Leitura humana

- Profundidade interpretativa
- Capta ironia, contexto e o latente
- Inviável na escala do corpus
- Deriva entre leitores e ao longo do tempo

Automação

- Escala arbitrária
- Consistência técnica de aplicação
- Cega ao contexto não explicitado
- Aprende os vieses do corpus de treino

A pergunta correta não é qual dos dois é melhor.

É qual inferência eu preciso sustentar, e com que evidência de validade.

Os três princípios de Grimmer e Stewart (2013)

Artigo fundador do campo em Ciência Política. Três teses que continuam valendo:

- 1 Todos os modelos quantitativos de linguagem estão errados, mas alguns são úteis.** Nenhum representa a linguagem adequadamente. O critério é utilidade para a tarefa, e não realismo.

Os três princípios de Grimmer e Stewart (2013)

Artigo fundador do campo em Ciência Política. Três teses que continuam valendo:

- 1 Todos os modelos quantitativos de linguagem estão errados, mas alguns são úteis.** Nenhum representa a linguagem adequadamente. O critério é utilidade para a tarefa, e não realismo.
- 2 Métodos automatizados amplificam a leitura humana; não a substituem.** O texto continua sendo lido. O método decide onde ler.

Os três princípios de Grimmer e Stewart (2013)

Artigo fundador do campo em Ciência Política. Três teses que continuam valendo:

- 1 Todos os modelos quantitativos de linguagem estão errados, mas alguns são úteis.** Nenhum representa a linguagem adequadamente. O critério é utilidade para a tarefa, e não realismo.
- 2 Métodos automatizados amplificam a leitura humana; não a substituem.** O texto continua sendo lido. O método decide onde ler.
- 3 Não existe método globalmente melhor.** A escolha é função da tarefa, do corpus e do estimando.

Os três princípios de Grimmer e Stewart (2013)

Artigo fundador do campo em Ciência Política. Três teses que continuam valendo:


- 1 Todos os modelos quantitativos de linguagem estão errados, mas alguns são úteis.** Nenhum representa a linguagem adequadamente. O critério é utilidade para a tarefa, e não realismo.
- 2 Métodos automatizados amplificam a leitura humana; não a substituem.** O texto continua sendo lido. O método decide onde ler.
- 3 Não existe método globalmente melhor.** A escolha é função da tarefa, do corpus e do estimando.

O corolário que a literatura repete há treze anos

Validar, validar, validar. Aplicar um método sem validação em uma tarefa de ciências sociais não é análise. É geração de números.

O texto como dado: a virada e o que ela custou

- Por décadas, texto foi ilustração ou anedota na Ciência Política brasileira.
- A virada *text-as-data* reposiciona o texto como **unidade observacional sistemática**.
- Ganho: escala, replicabilidade técnica e regras auditáveis.
- Custo: perda de contexto, dependência de escolhas de pré-processamento e risco de reificar o que o corpus já contém.
- Na pós-graduação, a questão muda. Não é “é possível?”, e sim *em que condições a inferência sobrevive à escala?*



Uma ponte epistemológica, não a substituição de uma tradição pela outra.

Texto político é o caso mais puro de *found data*

Salganik (2018), *Bit by Bit*

A ciência social computacional não é a aplicação de ferramentas novas a perguntas velhas. É a exploração da tensão entre **dados encontrados** (*found data*) e **dados desenhados** (*designed data*).

- O texto não foi produzido para você. Foi produzido por atores estratégicos, em contextos institucionais específicos, com objetivos próprios.
- Sua estrutura reflete a instituição que o gerou, como regimento interno, tempo de fala e incentivo eleitoral, e não a sua pergunta.

Texto político é o caso mais puro de *found data*

Salganik (2018), *Bit by Bit*

A ciência social computacional não é a aplicação de ferramentas novas a perguntas velhas. É a exploração da tensão entre **dados encontrados** (*found data*) e **dados desenhados** (*designed data*).

- O texto não foi produzido para você. Foi produzido por atores estratégicos, em contextos institucionais específicos, com objetivos próprios.
- Sua estrutura reflete a instituição que o gerou, como regimento interno, tempo de fala e incentivo eleitoral, e não a sua pergunta.

Consequência de desenho

Todo estudo com texto precisa de uma teoria da produção do texto, isto é, do processo gerador dos dados.

O mesmo ponto, em um exemplo brasileiro

Discursos de plenário da Câmara

Boa parte do volume vem do Pequeno Expediente, em que o parlamentar fala sem competir por atenção e sem custo político relevante.

- Se você agregar tudo, estará medindo **a agenda do regimento**, e não a agenda estratégica do partido.
- A solução não é estatística. É de desenho: separar tipos de pronunciamento e justificar o recorte na seção de métodos.

O mesmo ponto, em um exemplo brasileiro

Discursos de plenário da Câmara

Boa parte do volume vem do Pequeno Expediente, em que o parlamentar fala sem competir por atenção e sem custo político relevante.

- Se você agregar tudo, estará medindo **a agenda do regimento**, e não a agenda estratégica do partido.
- A solução não é estatística. É de desenho: separar tipos de pronunciamento e justificar o recorte na seção de métodos.

Regra prática: antes de rodar qualquer modelo, escreva um parágrafo explicando *por que* esses documentos existem. Se você não consegue escrevê-lo, ainda não conhece seu corpus.

Onde estamos

1 Abertura

2 Taxonomia

3 Pré-processamento

4 Primeiros códigos

5 Validação

6 Fronteira

As quatro tarefas canônicas

Toda pergunta empírica com texto cai em uma destas quatro. Identificar a sua resolve a maior parte das decisões metodológicas seguintes.

Tarefa	Pergunta típica	Métodos	Validação
Descrever	O que há neste corpus? Como o vocabulário varia entre grupos?	Frequência, TF-IDF, <i>keyness</i> , coocorrência	Leitura de exemplos, KWIC
Classificar	Cada documento pertence a que categoria conhecida?	Dicionários, supervisionado, LLM	κ , F_1 , matriz de confusão
Medir	Onde cada ator está em uma dimensão latente?	Wordscores, Wordfish, IRT	Correlação com medidas externas
Descobrir	Que estruturas eu não antecipei existem aqui?	LDA, STM, <i>clustering</i>	Validação semântica e preditiva

O erro de tarefa mais comum na pós-graduação

Usar método de descoberta para responder pergunta de classificação

Rodar um LDA e depois afirmar que o “Tópico 3” corresponde à sua categoria teórica de interesse.

Por que isso falha:

- O tópico é uma distribuição de probabilidade sobre palavras, definida pelo que *co-ocorre* no corpus. Sua categoria é definida pela teoria.
- Nada garante que os dois coincidam. Frequentemente o tópico mistura duas categorias suas, ou divide uma delas em três.
- Você só descobre isso lendo os documentos. E, se vai ter de ler, talvez a tarefa fosse de classificação desde o início.

O erro de tarefa mais comum na pós-graduação

Usar método de descoberta para responder pergunta de classificação


Rodar um LDA e depois afirmar que o “Tópico 3” corresponde à sua categoria teórica de interesse.

Por que isso falha:

- O tópico é uma distribuição de probabilidade sobre palavras, definida pelo que *co-ocorre* no corpus. Sua categoria é definida pela teoria.
- Nada garante que os dois coincidam. Frequentemente o tópico mistura duas categorias suas, ou divide uma delas em três.
- Você só descobre isso lendo os documentos. E, se vai ter de ler, talvez a tarefa fosse de classificação desde o início.

Uso legítimo do LDA: exploração inicial, construção indutiva de categorias e detecção de estruturas que você não antecipou. Nunca como substituto de um codebook.

Fluxo de decisão



Atenção ao ramo laranja. “Não sei minhas categorias” é resposta legítima e frequentemente honesta, mas obriga a uma etapa interpretativa posterior que é sua responsabilidade, e não do algoritmo.

O que a análise de conteúdo clássica já resolvia

Não estamos começando do zero. A análise de conteúdo categorial já formalizou o núcleo do problema.

Herdado e ainda obrigatório

- Unidade de amostragem, de registro e de contexto
- Codebook com definições operacionais
- Exclusão mútua, exaustividade e pertinência
- Pré-teste das categorias
- Confiabilidade intercodificador

Krippendorff (2018); Neuendorf (2017); Sampaio e Lycarião (2021).

O que a escala acrescentou

- O codificador pode ser um algoritmo
- A confiabilidade passa a ser humano contra máquina
- Surge o viés de corpus, ausente na codificação manual
- Surge a não reprodutibilidade dos modelos generativos

A tese que organiza o workshop

Enunciado

A automação **não relaxa** nenhuma exigência da análise de conteúdo clássica. Ela transfere o ônus da validação do momento da codificação para o momento da auditoria.

Três implicações práticas:

- 1 Você continua precisando de um codebook explícito, mesmo usando LLM.
- 2 Você continua precisando de codificação humana, ainda que em amostra pequena.
- 3 Você continua precisando reportar concordância, agora entre humano e máquina.

Tudo o que vamos fazer à tarde é uma aplicação destas três frases.

Um alerta empírico sobre o padrão brasileiro

Sampaio et al. (2022) analisaram 549 artigos da SciELO Brasil (2002 a 2020) que aplicaram análise de conteúdo qualitativa.

Dimensão de qualidade	% dos artigos
Explicitam a unidade de análise	0,9%
Mencionam múltiplos codificadores	14%
Mencionam treinamento de codificadores	0,5%
Apresentam teste de confiabilidade	2,6%
Apresentam validação dos dados	7,3%
Apresentam transparência metodológica	2,4%

Em revistas internacionais de *Communication* (1985 a 2010), 76% reportam algum teste de confiabilidade (Lovejoy et al., 2014).

Um alerta empírico sobre o padrão brasileiro

Sampaio et al. (2022) analisaram 549 artigos da SciELO Brasil (2002 a 2020) que aplicaram análise de conteúdo qualitativa.

Dimensão de qualidade	% dos artigos
Explicitam a unidade de análise	0,9%
Mencionam múltiplos codificadores	14%
Mencionam treinamento de codificadores	0,5%
Apresentam teste de confiabilidade	2,6%
Apresentam validação dos dados	7,3%
Apresentam transparência metodológica	2,4%


Em revistas internacionais de *Communication* (1985 a 2010), 76% reportam algum teste de confiabilidade (Lovejoy et al., 2014).

Implicação para vocês: o custo marginal de fazer certo é baixo e o retorno em diferenciação é alto.

Onde estamos

- 1 Abertura
- 2 Taxonomia
- 3 Pré-processamento**
- 4 Primeiros códigos
- 5 Validação
- 6 Fronteira

Do texto ao dado: a cadeia de decisões



Cada seta é uma decisão de pesquisa, não um passo técnico

- **Unidade de registro:** o discurso inteiro, o parágrafo ou a frase? Muda o N , muda a variância e muda o que o modelo enxerga.
- **Stopwords:** “não” é stopwords? Em análise de posicionamento, remover a negação destrói o sinal.
- **Lematização:** colapsa “governar”, “governo” e “governança”, que podem ser teoricamente distintos.
- **Bigramas:** “segurança pública” separada em dois unigramas é outra coisa.

Pré-processamento é um grau de liberdade do pesquisador

Existem sete decisões binárias usuais (minúsculas, lematização, pontuação, números, stopwords, termos infrequentes e n -gramas). Isso gera 128 especificações possíveis do *mesmo* corpus.

O risco

Tratar essas escolhas como etapa técnica e não reportá-las é uma forma silenciosa de *p-hacking* textual. Métodos não supervisionados são particularmente sensíveis: especificações distintas produzem agrupamentos distintos.

O que fazer:

- 1 Justifique cada decisão teoricamente, em uma frase que você escreveria na seção de métodos.
- 2 Reporte todas as decisões, inclusive as que parecem triviais.
- 3 Apresente robustez para ao menos uma especificação alternativa.

Discussão sistemática em Denny e Spirling (2018).

Um exemplo brasileiro de decisão substantiva

Stopwords legislativas

Um dicionário genérico do português *não* remove:

- “Sr. Presidente” e “nobre deputado”
- “Vossa Excelência” e “Mesa Diretora”
- “pela ordem” e “em tempo”

Esses termos dominam qualquer contagem e escondem o conteúdo substantivo.

Mas cuidado com o excesso

Remover siglas partidárias (PT, PL e PSOL) elimina justamente a variação que interessa em análise de posicionamento.

Por isso o acR tem o argumento `protect`: você declara explicitamente o que não pode ser tocado pela limpeza.

Um exemplo brasileiro de decisão substantiva

Stopwords legislativas

Um dicionário genérico do português *não* remove:

- “Sr. Presidente” e “nobre deputado”
- “Vossa Excelência” e “Mesa Diretora”
- “pela ordem” e “em tempo”

Esses termos dominam qualquer contagem e escondem o conteúdo substantivo.

Mas cuidado com o excesso

Remover siglas partidárias (PT, PL e PSOL) elimina justamente a variação que interessa em análise de posicionamento.

Por isso o acR tem o argumento `protect`: você declara explicitamente o que não pode ser tocado pela limpeza.

Regra operacional

Toda stopword removida deve ter justificativa que você escreveria na seção de métodos. Se você não consegue escrever a frase, não remova.

Onde estamos

- 1 Abertura
- 2 Taxonomia
- 3 Pré-processamento
- 4 Primeiros códigos**
- 5 Validação
- 6 Fronteira

Ecosistema em R: o que usar e quando

Pacote	Função	Quando usar
quanteda	Pipeline geral de análise textual	Padrão internacional: tokenização, DFM, KWIC e <i>keyness</i>
tidytext	Texto no paradigma tidyverse	Descritivas e integração com dplyr e ggplot2
stm	<i>Structural Topic Models</i>	Tópicos com covariáveis, como partido e ano
quanteda.textmodels	Wordfish, Wordscores e Naive Bayes	Escalonamento e classificação supervisionada
irr, irrCAC	κ , α e AC1	Confiabilidade intercodificador
ellmer	Interface unificada a LLMs	Backend de provedores comerciais e locais
acR	Pipeline integrado quali e quanti	Corpora brasileiros, coleta Câmara e Senado, métricas embutidas

Demo 0. Preparando o ambiente

```
# Script 00: setup. Rode UMA VEZ.

pacotes <- c("tidyverse", "quanteda", "quanteda.textstats",
            "tidytext", "stm", "irr", "irrCAC", "remotes")

instalar <- pacotes[!pacotes %in% rownames(installed.packages())]
if (length(instalar) > 0) install.packages(instalar)

# acR ainda em submissao a CRAN; instalar do GitHub
remotes::install_github("andersonheri/acR")

library(acR)
packageVersion("acR")
```

```
[1] '0.3.2'
```

Por que registrar a versão: versões de pacote mudam resultados. Guarde a saída de `sessionInfo()` no seu log. Sem isso, o script é compartilhável, mas não replicável.

Demo 1. Do arquivo ao corpus

```
library(acR)

# Caminho A: seus arquivos (PDF, DOCX, XLSX, CSV, TXT, imagem com OCR)
corpus_raw <- ac_import("dados/*.pdf")

# Caminho B: coleta nativa da Camara dos Deputados
corpus_raw <- ac_fetch_camara(data_inicio = "2024-03-11",
                              data_fim    = "2024-03-15",
                              tipo_discurso = "plenario",
                              n_max       = 300L)

# Estruturar como objeto ac_corpus (texto + metadados + idioma)
corpus <- ac_corpus(corpus_raw, text = texto, docid = id_discurso)
```

```
<ac_corpus> 300 documentos | idioma: pt | 4 variaveis de metadados
  docid      partido  uf   data
1 disc-000841    PT    PE 2024-03-11
2 disc-000842    PL    SP 2024-03-11
```

Demo 1. A decisão escondida neste bloco

docid define a unidade de registro

Se você quiser codificar por parágrafo, e não por discurso inteiro, o *split* precisa acontecer **antes** de `ac_corpus()`.

```
# Unidade de registro = paragrafo
corpus_par <- corpus_raw |>
  tidyr::separate_rows(texto, sep = "\n\n") |>
  dplyr::mutate(id_par = paste0(id_discurso, "-p", dplyr::row_number())) |>
  ac_corpus(text = texto, docid = id_par)
```

Consequência: o *N* salta de 300 para cerca de 2.400. Isso muda a prevalência das categorias, o custo de codificação e a interpretação de qualquer teste estatístico posterior. Registre a escolha e justifique-a.

Demo 2. Limpeza como decisão teórica

```
# Construa o vetor de stopwords ANTES de limpar, para inspecionar
sw <- ac_clean_stopwords(preset = "pt-legislativo",
                        add      = c("nobre", "ilustre", "orador"),
                        remove   = c("lei", "projeto", "constituicao"))

corpus_limpo <- ac_clean(corpus,
                        remove_stopwords = "pt-legislativo",
                        extra_stopwords  = sw,
                        protect          = c("PT", "PL", "PSOL"),
                        normalize_pt    = TRUE,
                        min_char        = 3L,
                        verbose          = TRUE)
```

```
-- ac_clean() -----
Tokens antes: 412.877 | Tokens depois: 168.204 (-59,3%)
  stopwords -196.441 pontuacao -38.117   min_char -10.115
Documentos vazios apos limpeza: 2 (removidos)
Termos protegidos preservados: PT, PL, PSOL
```

Leia esse relatório de limpeza antes de seguir

O que checar na saída

- Perdeu mais de 60% dos tokens? Normal em texto legislativo, mas confirme que não removeu conteúdo.
- Documentos vazios indicam pronunciamentos puramente procedimentais. Decida se saem do corpus ou viram categoria própria.
- Os termos protegidos sobreviveram?

Cole no seu log

Essa saída é a evidência de que a limpeza não destruiu o corpus. Ela pertence ao material de replicação, junto com o script.

Teste rápido de sanidade: imprima cinco documentos limpos e leia-os. Se você não consegue entender do que tratam, a limpeza foi longe demais.


Demo 3. Descrever: frequência

```
contagem <- ac_count(corpus_limpo)
ac_top_terms(contagem, n = 15) |>
  ac_plot_top_terms()
```

Como ler: a contagem bruta mostra do que o corpus trata, mas ainda não diz nada sobre variação entre grupos.

Saída ilustrativa, gerada para fins didáticos.

Termos mais frequentes no corpus (n = 300 pronunciamentos)




Demo 3. Descrever: distintividade entre grupos

```
# TF-IDF: o que é DISTINTIVO
freq_partido <- ac_count(corpus_limp,
                        by = "partido")
tfidf <- ac_tf_idf(freq_partido,
                  by = "partido")

# Keyness: teste estatístico
kn <- ac_keyness(freq_partido,
                 group = "partido",
                 target = "PT")
ac_plot_keyness(kn)
```

Keyness compara a frequência observada de cada termo no grupo-alvo com a esperada sob o grupo de referência.

Termos distintivos: PT (azul) e PL (laranja)



Saída ilustrativa, gerada para fins didáticos.


Demo 3. Descrever: nuvem de palavras

```
ac_wordcloud(contagem, max_words = 40)
```

A versão de impacto visual da Figura 1 (frequência): mesmo dado, tamanho da fonte no lugar do comprimento da barra.

Cuidado

Tamanho de fonte não é uma escala perceptualmente linear: o olho superestima palavras grandes. Para leitura analítica precisa, a barra continua sendo mais honesta que a nuvem.



Saída ilustrativa, gerada para fins didáticos.

Demo 3. Descrever: nuvem comparativa entre grupos

```
ac_plot_wordcloud_comparative(  
    corpus_limpo,  
    group      = partido,  
    max_words  = 25  
)
```

A versão visual da Figura 2 (*keyness*): usa TF-IDF, tratando cada grupo como um "documento", para destacar o vocabulário distintivo de cada lado, lado a lado. Ganha em leitura rápida, perde em rigor: aqui não há valor-p nem intervalo, só o ranking de TF-IDF.

Termos distintivos por grupo (TF-IDF) • top 25 por grupo

oposicao

situacao

acredita custa
ano **saude**
dinheiro
processo
sobra ate

algo antes
acessibilidade
ainda
espaco
area anos custo

acR • ac_plot_wordcloud_comparative()

Saída ilustrativa, gerada para fins didáticos.

Interpretando a saída: três perguntas obrigatórias

Diante de qualquer tabela de frequência ou de *keyness*:

1 Quem produziu esses termos?

Verifique concentração por autor. Um deputado com 400 pronunciamentos domina qualquer contagem agregada.

2 O termo significa a mesma coisa nos dois grupos?

“Reforma” em 1995 e em 2019 não são o mesmo objeto. Comparar períodos exige atenção ao deslocamento semântico.

3 O que eu esperaria ver se minha hipótese fosse falsa?

Sem essa resposta, qualquer lista de palavras confirma qualquer narrativa.

A ferramenta de disciplina: voltar ao texto

```
# KWIC: onde e como o termo aparece, no contexto original
library(quanteda)
tokens_qt <- quanteda::tokens(corpus_limpo$text)
kwic(tokens_qt, pattern = "impunidade", window = 6) |> head(4)
```

docname	pre	keyword	post
disc-000912	"a sensacao de"	impunidade	"que toma conta do pais"
disc-001044	"combater a"	impunidade	"significa investir em"
disc-001156	"falar em"	impunidade	"sem falar em desigualdade"
disc-001203	"o discurso da"	impunidade	"serve para justificar"

Note o que aconteceu


O mesmo termo aparece em posições argumentativas **opostas**. Uma contagem agregada trataria os quatro casos como equivalentes. Custa dois minutos verificar, e evita uma conclusão falsa.

Demo 4. Descobrir: modelagem de tópicos

```
# SEMPRE fixe a seed  
lda <- ac_lda(corpus_limpo,  
             k = 4,  
             seed = 1234)  
  
ac_plot_lda_topics(lda)
```

O LDA trata cada documento como mistura de k tópicos latentes, e cada tópico como distribuição sobre palavras.

Saída ilustrativa, gerada para fins didáticos.



Repare no Tópico 4: ele capturou vocabulário procedimental, não substantivo. Isso é comum e precisa ser reportado.


Como escolher k: existe uma métrica

```
tune <- ac_lda_tune(corpus_limpo,  
                   k_range = 2:10)  
ac_plot_lda_tune(tune)
```

`ac_lda_tune()` testa vários k e calcula a **perplexidade**: quanto menor, melhor o modelo prevê palavras que não viu.

Seleção do número de tópicos (k)

Menor perplexidade indica melhor ajuste



Saída ilustrativa, gerada para fins didáticos.

Leia o “cotovelo”, não o mínimo. Piso, não teto: a palavra final ainda depende de ler os tópicos.

LDA ou STM? Depende da sua pergunta

LDA (o que rodamos)

- Tópicos “soltos”, sem metadado do corpus.
- Responde: *quais tópicos existem?*
- Comparar com partido/período é manual, depois.

STM (pacote stm)

- Covariável **dentro** do modelo: na prevalência (quanto se fala) e no conteúdo (como se fala).
- Responde: *como o tópico varia por X?*
- Custa mais: exige especificar a covariável.

Regra prática

Pergunta é *quais tópicos existem?* Use LDA (`ac_lda()`). Pergunta já é *como o tópico varia por partido/período?* Comece direto no STM: comparar tópicos de um LDA plano depois é mais frágil do que modelar a covariável desde o início.

Roberts, Stewart e Tingley. `stm`: An R Package for Structural Topic Models. *J. Statistical Software*, v. 91, n. 2, 2019.

A armadilha do k

Não existe k correto

Métricas de coerência e exclusividade ajudam a delimitar uma faixa razoável, mas a decisão final é interpretativa e é sua.

O passo mais frágil de toda a literatura aplicada: nomear os tópicos lendo as dez palavras mais prováveis.

- Nomear não é validar.
- A leitura das palavras principais gera uma narrativa plausível para praticamente qualquer conjunto de termos.
- O nome do tópico entra no artigo como se fosse um achado, quando é uma interpretação não testada.

Como validar um modelo de tópicos: o mínimo aceitável

- 1 **Validação semântica.** Leia uma amostra aleatória dos documentos com maior probabilidade em cada tópico. O rótulo sobrevive à leitura?
- 2 **Teste de intrusão.** Insira uma palavra estranha entre as principais do tópico. Codificadores humanos a identificam? Se não, o tópico não é coerente.
- 3 **Validação preditiva.** O tópico se comporta como esperado diante de choques externos conhecidos, como eleição ou crise?
- 4 **Estabilidade.** O tópico sobrevive a mudanças de k , de *seed* e de pré-processamento?

Como validar um modelo de tópicos: o mínimo aceitável

- 1 **Validação semântica.** Leia uma amostra aleatória dos documentos com maior probabilidade em cada tópico. O rótulo sobrevive à leitura?
- 2 **Teste de intrusão.** Insira uma palavra estranha entre as principais do tópico. Codificadores humanos a identificam? Se não, o tópico não é coerente.
- 3 **Validação preditiva.** O tópico se comporta como esperado diante de choques externos conhecidos, como eleição ou crise?
- 4 **Estabilidade.** O tópico sobrevive a mudanças de k , de *seed* e de pré-processamento?

Padrão de reporte honesto

“Dos 20 tópicos estimados, 12 foram interpretáveis e 8 descartados como ruído de vocabulário procedimental.” Isso é ciência. Apresentar os 20 como se todos significassem algo, não é.


Descobrir tipos de documento: clustering

```
clust <- ac_cluster_documents(  
  corpus_limpo, k = 2)  
ac_plot_cluster(clust)
```

Diferença para o LDA: *soft* (mistura de tópicos) vs. *hard* (uma única etiqueta por documento).

Dendrograma dos documentos

Metodo: hclust (Ward.D2) • k = 2 • dist: cosine



Saída ilustrativa, gerada para fins didáticos.

Quando usar: tipologias latentes, amostra de revisão estratificada, ou dendrograma no lugar de tópicos.

`hclust` (padrão), `kmeans` ou `pam`.

Onde estamos

- 1 Abertura
- 2 Taxonomia
- 3 Pré-processamento
- 4 Primeiros códigos
- 5 Validação**
- 6 Fronteira

Validação não é etapa: é critério de existência

O ponto epistemológico da manhã

Uma categoria que dois codificadores treinados não conseguem aplicar de forma convergente **não existe como objeto intersubjetivo**. É leitura idiossincrática com aparência de método.

Isso vale igualmente quando um dos codificadores é um algoritmo.

Categoria rara: 95% “não”.
Dois codificadores desatentos
marcam tudo como “não”

Concordância bruta: 95%.
Informação sobre a categoria: zero

Métricas de confiabilidade: quando usar cada uma

Métrica	Quando usar	Corte de referência	Fonte
κ de Cohen	2 codificadores, dados nominais	$\geq 0,70$ publicável; $\geq 0,80$ seguro	Cohen (1960); Landis e Koch (1977)
κ de Fleiss	3 ou mais codificadores, nominais	Mesmos cortes	Fleiss (1971)
α de Krippendorff	N codificadores, escalas mistas, dados faltantes	$\geq 0,667$ mínimo; $\geq 0,80$ confortável	Krippendorff (2018)
AC1 de Gwet	Categorias desbalanceadas	$\geq 0,70$	Gwet (2008)
F_1 macro	Avaliação contra <i>gold standard</i>	Depende da tarefa	Literatura de ML

Toda essa família de métricas existe para descontar a concordância esperada pelo acaso. Elas diferem apenas em como estimam esse acaso.

κ baixo com prevalência desbalanceada: o que fazer

O paradoxo (Feinstein e Cicchetti, 1990): com prevalência desbalanceada, dá para ter concordância bruta altíssima e κ perto de zero, ou negativo. O problema é a distribuição marginal, não a codificação.

As quatro ações, em ordem

- 1 Reporte em conjunto:** concordância bruta, κ/α e AC1 de Gwet, que não sofre o mesmo colapso com categorias desbalanceadas.
- 2 Apresente a matriz de confusão:** mostra onde está o desacordo, o que nenhum número agregado mostra sozinho.
- 3 Sobreamostre as categorias raras** no teste de confiabilidade, para ter casos suficientes delas.
- 4 Nunca reporte só o número que favorece seu argumento.** Se κ é ruim mas AC1 é bom, reporte os dois e explique.

Para a tarde: o acR calcula todas essas métricas simultaneamente, com intervalo de confiança por *bootstrap*.

Onde estamos

- 1 Abertura
- 2 Taxonomia
- 3 Pré-processamento
- 4 Primeiros códigos
- 5 Validação
- 6 Fronteira**

LLMs entram no pipeline: o que mudou

- Classificação *zero-shot* e *few-shot* com desempenho competitivo em várias tarefas de anotação (Gilardi, Alizadeh e Kubli, 2023).
- Queda acentuada no custo de construir dados rotulados, o gargalo histórico da classificação supervisionada.
- O modelo pode justificar a decisão, o que torna a codificação auditável em linguagem natural.
- Categorias complexas, que exigem inferência contextual, passam a ser tratáveis em escala.

LLMs entram no pipeline: o que mudou

- Classificação *zero-shot* e *few-shot* com desempenho competitivo em várias tarefas de anotação (Gilardi, Alizadeh e Kubli, 2023).
- Queda acentuada no custo de construir dados rotulados, o gargalo histórico da classificação supervisionada.
- O modelo pode justificar a decisão, o que torna a codificação auditável em linguagem natural.
- Categorias complexas, que exigem inferência contextual, passam a ser tratáveis em escala.

Nada disso é pouco. Mas repare que todos os ganhos são de **custo e cobertura**, não de **validade**.

LLMs entram no pipeline: o que não mudou

- Você continua precisando de um codebook explícito.
- Você continua precisando de um *gold standard* humano.
- Você continua precisando reportar concordância por categoria.

O problema técnico central, que veremos à tarde

Os erros do modelo são **sistemáticos**, e não aleatórios. Usar rótulos de LLM como se fossem observados envia coeficientes de regressão, e esse viés não desaparece com N maior.

A literatura recente propõe correções que combinam uma amostra pequena rotulada por humanos com uma amostra grande rotulada pela máquina.

Riscos que exigem tratamento explícito no artigo (1 de 2)

1 Não determinismo.

O mesmo *prompt*, no mesmo modelo, em datas diferentes, pode gerar rótulos diferentes. Fixe versão do modelo, temperatura e *seed* quando disponível, e reporte a data de execução.

2 Opacidade e contaminação.

Você não sabe o que há no treino. Contaminação com o próprio corpus é possível e, na prática, indetectável.

3 Viés de posição e de rótulo.

Modelos tendem a favorecer categorias listadas primeiro e rótulos mais frequentes na língua. Teste embaralhando a ordem das categorias.

Riscos que exigem tratamento explícito no artigo (2 de 2)

4 Deriva de versão.

O provedor atualiza o modelo e seu resultado deixa de replicar. Salve os *outputs* brutos, e não apenas o código.


5 Custo financeiro e energético.

Reporte o volume de chamadas e o modelo usado. É informação metodológica, não detalhe administrativo.

Regra que proponho

O *output* bruto do modelo é **dado primário** e deve ser depositado junto com o corpus, em Zenodo, OSF ou Dataverse. Sem isso, o trabalho é irrePLICável por construção.

Mapa conceitual do workshop



A validação é o nó que sustenta todas as arestas. É por ela que a tarde começa.

Síntese da manhã

- 1 A análise automatizada de texto herda integralmente as exigências da análise de conteúdo clássica e acrescenta outras.
- 2 Identifique sua tarefa (descrever, classificar, medir ou descobrir) antes de escolher a ferramenta.
- 3 Pré-processamento é decisão teórica. Justifique, reporte e teste robustez.
- 4 Nenhum resultado não supervisionado é interpretável sem validação semântica, de intrusão ou preditiva.
- 5 LLMs reduzem o custo de rotular, não o de validar. O erro deles é sistemático.

Tarefa de dez minutos para o almoço

Escreva uma frase: “Na minha pesquisa, a unidade de registro é _____, a categoria que preciso medir é _____ e ela seria validada por _____.” Vamos usar essa frase na atividade da tarde.

Referências: o cânone *text-as-data*

Leitura obrigatória para quem vai fazer

GRIMMER, Justin; STEWART, Brandon M. Text as data: the promise and pitfalls of automatic content analysis methods for political texts. *Political Analysis*, v. 21, n. 3, p. 267–297, 2013.

GRIMMER, Justin; ROBERTS, Margaret E.; STEWART, Brandon M. **Text as Data: a new framework for machine learning and the social sciences**. Princeton: Princeton University Press, 2022.

DENNY, Matthew J.; SPIRLING, Arthur. Text preprocessing for unsupervised learning: why it matters, when it misleads, and what to do about it. *Political Analysis*, v. 26, n. 2, p. 168–189, 2018.

Panoramas

WILKERSON, John; CASAS, Andreu. Large-scale computerized text analysis in political science: opportunities and challenges. *Annual Review of Political Science*, v. 20, p. 529–544, 2017.

GENTZKOW, Matthew; KELLY, Bryan; TADDY, Matt. Text as data. *Journal of Economic Literature*, v. 57, n. 3, p. 535–574, 2019.

SALGANIK, Matthew J. **Bit by Bit: social research in the digital age**. Princeton: Princeton University Press, 2018.

Referências: métodos específicos

Escalonamento e classificação

LAVER, Michael; BENOIT, Kenneth; GARRY, John. Extracting policy positions from political texts using words as data. *American Political Science Review*, v. 97, n. 2, p. 311–331, 2003.

SLAPIN, Jonathan B.; PROKSCH, Sven-Oliver. A scaling model for estimating time-series party positions from texts. *American Journal of Political Science*, v. 52, n. 3, p. 705–722, 2008.

HOPKINS, Daniel J.; KING, Gary. A method of automated nonparametric content analysis for social science. *American Journal of Political Science*, v. 54, n. 1, p. 229–247, 2010.

BARBERÁ, Pablo et al. Automated text classification of news articles: a practical guide. *Political Analysis*, v. 29, n. 1, p. 19–42, 2021.

Tópicos e *embeddings*

ROBERTS, Margaret E. et al. Structural topic models for open-ended survey responses. *American Journal of Political Science*, v. 58, n. 4, p. 1064–1082, 2014.

RODRIGUEZ, Pedro L.; SPIRLING, Arthur. Word embeddings: what works, what doesn't, and how to tell the difference for applied research. *Journal of Politics*, v. 84, n. 1, p. 101–115, 2022.

Referências: análise de conteúdo e confiabilidade

Fundamentos e manuais aplicados

- KRIPPENDORFF, Klaus. **Content Analysis: an introduction to its methodology**. 4. ed. Thousand Oaks: Sage, 2018.
- NEUENDORF, Kimberly A. **The Content Analysis Guidebook**. 2. ed. Thousand Oaks: Sage, 2017.
- SAMPAIO, Rafael Cardoso; LYCARIÃO, Diógenes. **Análise de conteúdo categorial: manual de aplicação**. Brasília: Enap, 2021.
- BARDIN, Laurence. **Análise de Conteúdo**. São Paulo: Edições 70, 2011.

Métricas de concordância

- COHEN, Jacob. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, v. 20, n. 1, p. 37–46, 1960.
- LANDIS, J. Richard; KOCH, Gary G. The measurement of observer agreement for categorical data. *Biometrics*, v. 33, n. 1, p. 159–174, 1977.
- GWET, Kilem L. Computing inter-rater reliability and its variance in the presence of high agreement. *British Journal of Mathematical and Statistical Psychology*, v. 61, n. 1, p. 29–48, 2008.

Referências: o paradoxo do kappa

Leitura essencial antes de reportar concordância

FEINSTEIN, Alvan R.; CICCHETTI, Domenic V. High agreement but low kappa: I. The problems of two paradoxes. *Journal of Clinical Epidemiology*, v. 43, n. 6, p. 543–549, 1990.

CICCHETTI, Domenic V.; FEINSTEIN, Alvan R. High agreement but low kappa: II. Resolving the paradoxes. *Journal of Clinical Epidemiology*, v. 43, n. 6, p. 551–558, 1990.

GWET, Kilem L. **Handbook of Inter-Rater Reliability**. 4. ed. Gaithersburg: Advanced Analytics, 2014.

Por que separei esta referência

Este é o problema que mais aparece em corpora políticos brasileiros, em que a categoria de interesse costuma ser rara. Se você for reportar κ com prevalência abaixo de 10%, leia os dois artigos antes.

Referências: debate brasileiro, LLMs e software

Produção brasileira

IZUMI, Mauricio; MOREIRA, Davi. O texto como dado: desafios e oportunidades para as ciências sociais. *BIB — Revista Brasileira de Informação Bibliográfica em Ciências Sociais*, n. 86, p. 138–174, 2018.

SAMPAIO, Rafael Cardoso et al. Muita Bardin, pouca qualidade: uma avaliação sobre as análises de conteúdo qualitativas no Brasil. *Revista Pesquisa Qualitativa*, v. 10, n. 25, p. 464–494, 2022.

LOVEJOY, Jennette et al. Assessing the reporting of reliability in published content analyses: 1985–2010. *Communication Methods and Measures*, v. 8, n. 3, p. 207–221, 2014.

LLMs em anotação e software

GILARDI, Fabrizio; ALIZADEH, Meysam; KUBLI, Maël. ChatGPT outperforms crowd workers for text-annotation tasks. *PNAS*, v. 120, n. 30, 2023.

BENOIT, Kenneth et al. quanteda: an R package for the quantitative analysis of textual data. *Journal of Open Source Software*, v. 3, n. 30, 2018.

HENRIQUE, Anderson. **acR**: análise de conteúdo em R. Pacote R versão 0.3.2, 2026. Disponível em: <https://ahenriquecp.com/acR/>.

Intervalo para o almoço

Voltamos às 13h30, para a parte prática

Antes de voltar:

1. Confirme que `library(acR)` roda sem erro.
2. Baixe o repositório do workshop.
3. Traga sua frase: unidade de registro, categoria e validação.

`github.com/andersonheri/sicss-brazil-2026-text`

Como citar: HENRIQUE, Anderson. *Análise Automatizada de Texto: estado da arte, desenho de pesquisa e primeiros códigos em R*. 2026. Apresentação em slides: material didático não publicado, elaborado para o Summer Institute in Computational Social Science, Brazil (SICSS-Brazil 2026), Fundação Getulio Vargas, Rio de Janeiro. CEM-USP / INCT QualiGov.